



Data Science & Business Analytics

Machine Learning Models

David Issá

davidribeiro.issa@gmail.com

1. Árvores de Decisão

1. Árvores de Decisão

- Algoritmos não paramétricos de supervised learning usados para classificação ou regressão.
- Uma das principais vantagens é o facto da **solução do modelo representa um conjunto de regras**, fáceis de interpretar.




1. Árvores de Decisão

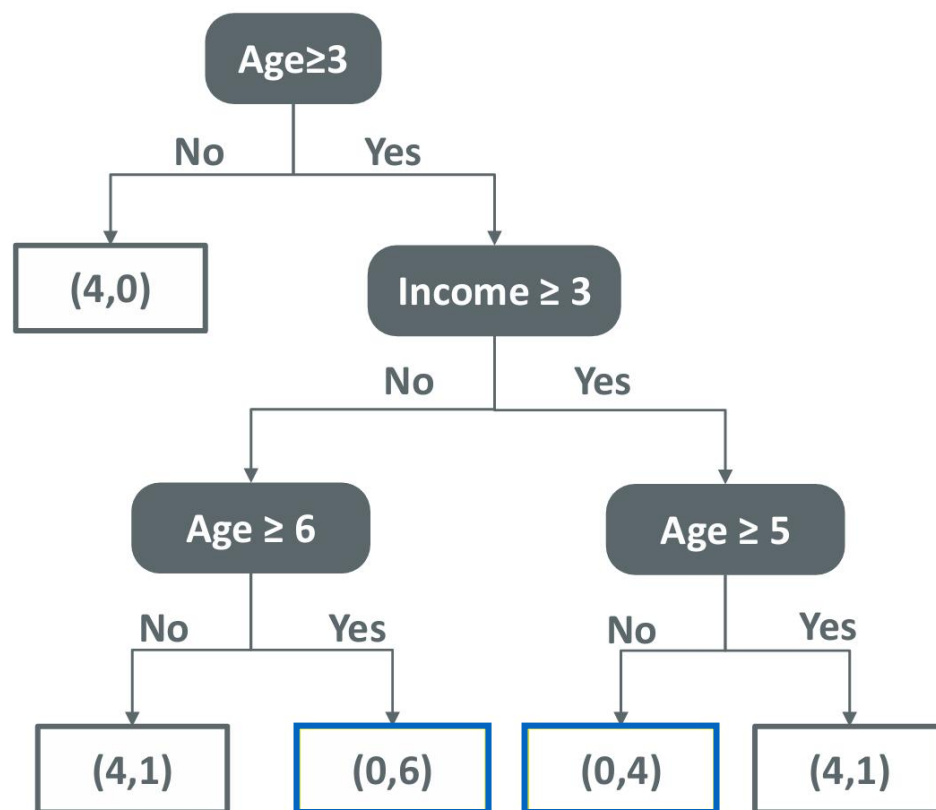

- Algoritmos não paramétricos de supervised learning usados para classificação ou regressão.
- Uma das principais vantagens é o facto da **solução do modelo representa um conjunto de regras**, fáceis de interpretar.
- Em alguns problemas, estamos apenas interessados em obter a melhor precisão possível. **Noutros, estamos mais interessados em compreender os resultados e a forma como o modelo está a produzir as estimativas!**

Interpretabilidade

1. Árvores de Decisão – Classificação

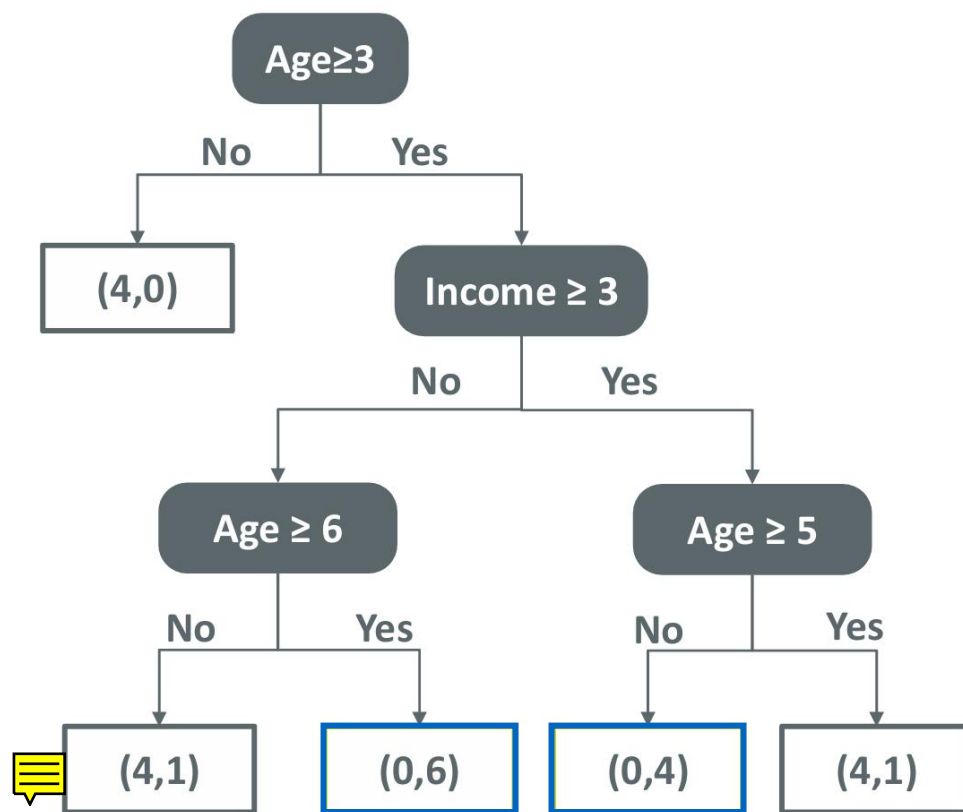



1. Árvores de Decisão – Classificação



1. Árvores de Decisão – Classificação

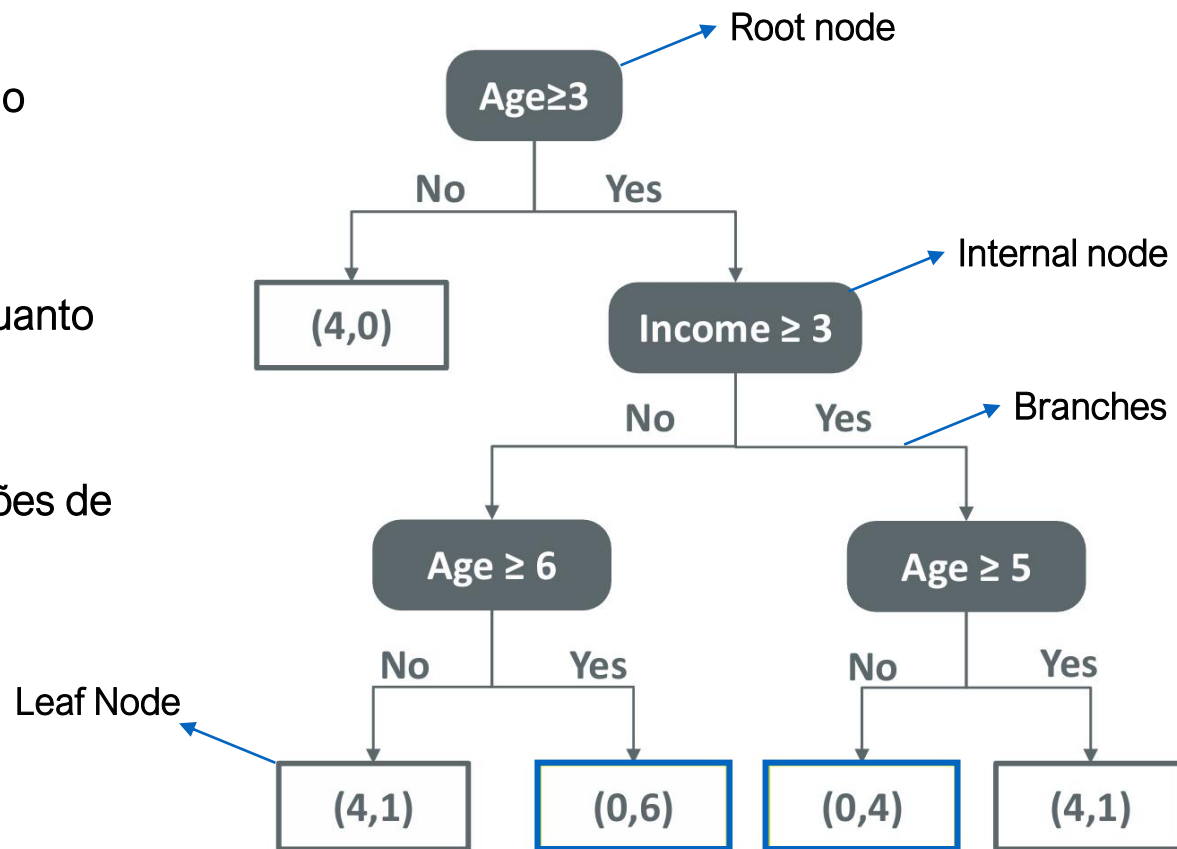
E se tivermos uma nova observação
onde Age = 5 e Income = 1?




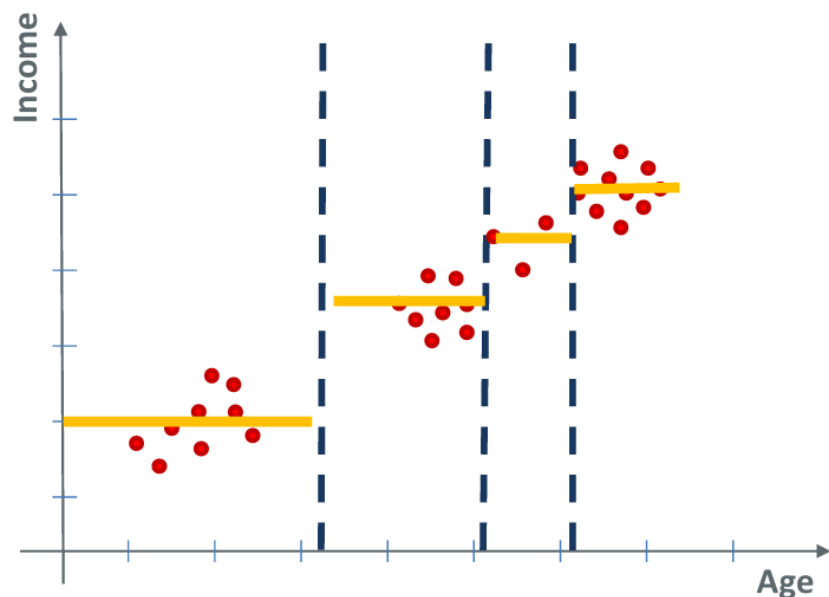
1. Árvores de Decisão – Classificação

Num problema de classificação, o objetivo é:

- Discriminar entre classes;
- Obter leaf nodes tão puras quanto possível;
- Idealmente, cada leaf node represente apenas observações de uma determinada classe.




1. Árvores de Decisão – Regressão



1. Árvores de Decisão – Regressão

Num problema de regressão, o objetivo é:

- Segmentar as variáveis independentes de modo a que as observações sejam o mais parecidas possíveis relativamente à variável a prever.
- O valor das leaf nodes devem ser o mais próximos possíveis das observações que a compõem.



1. Árvores de Decisão – Regras extraídas

- Cada branch adiciona uma conjunção (\wedge);
- Cada leaf adiciona uma disjunção (\vee)

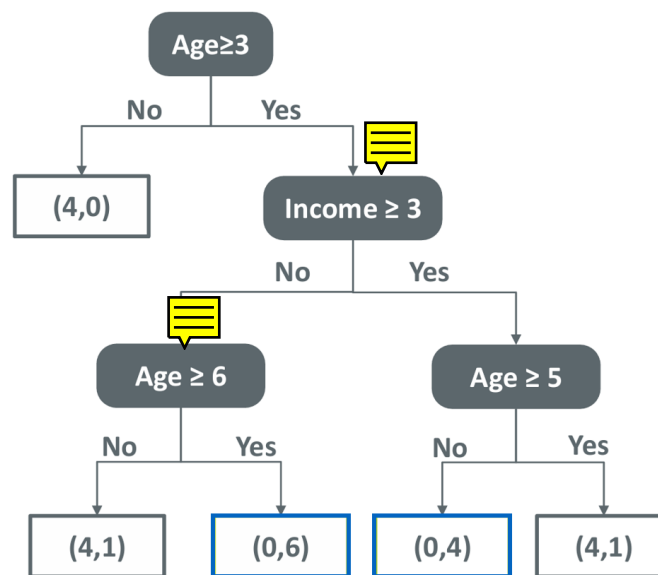
● $\leftrightarrow (age < 3)$

▲ $\leftrightarrow (age \geq 3) \wedge (income < 3) \wedge (age \geq 6)$

▲ $\leftrightarrow (age \geq 3) \wedge (income \geq 3) \wedge (age < 5)$

● $\leftrightarrow (age \geq 3) \wedge (income < 3) \wedge (age < 6)$


● $\leftrightarrow (age \geq 3) \wedge (income \geq 3) \wedge (age \geq 5)$



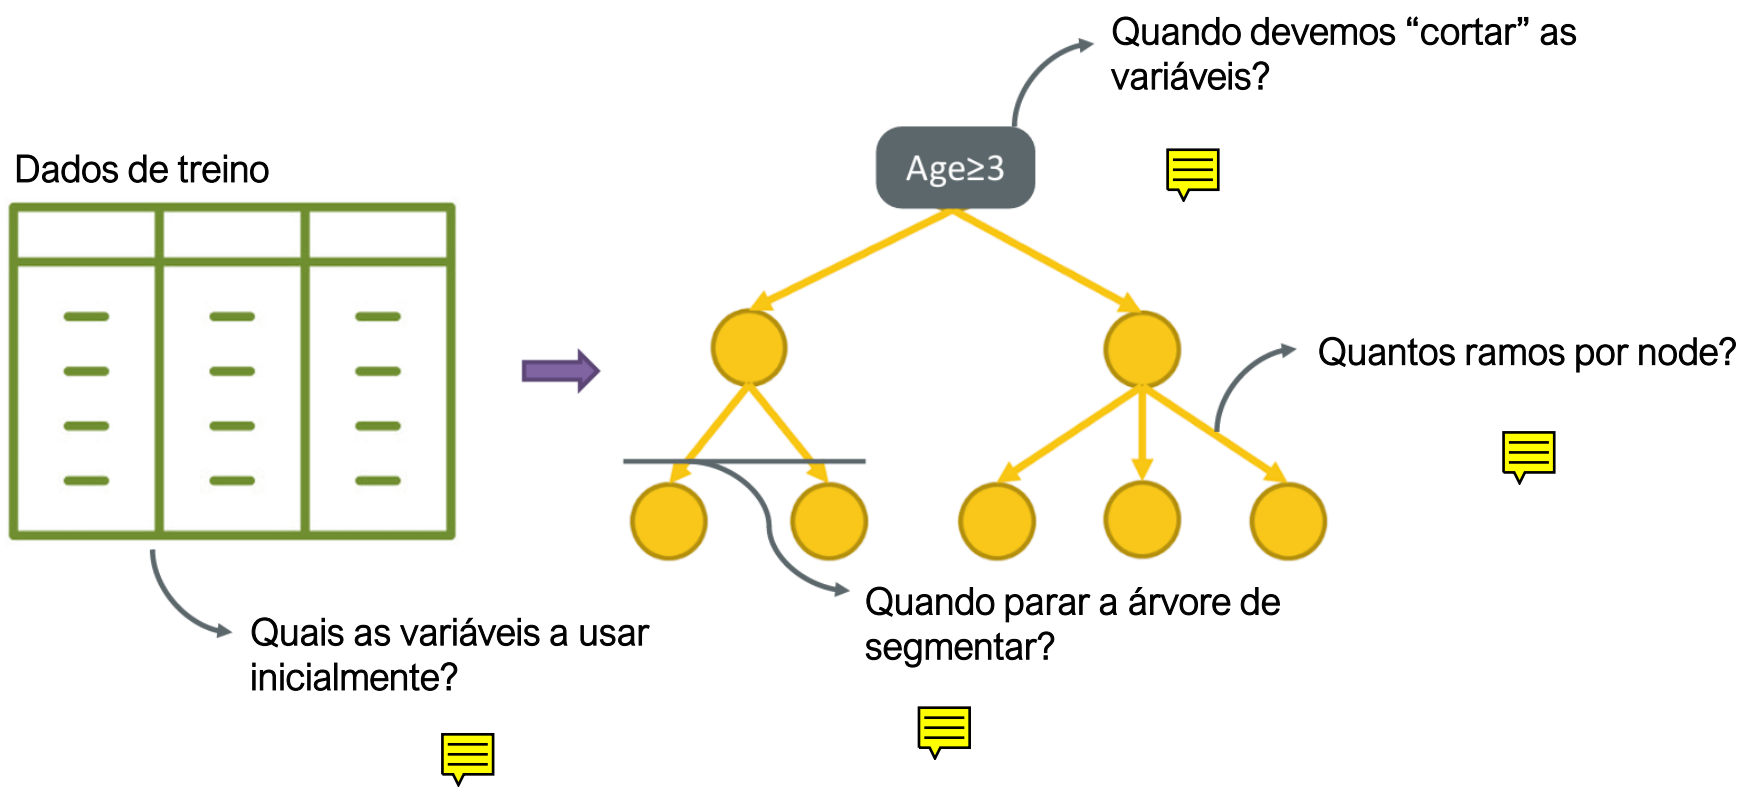
● $\leftrightarrow (age < 3) \vee ((age \geq 3) \wedge (income < 3) \wedge (age < 6)) \vee ((age \geq 3) \wedge (income \geq 3) \wedge (age \geq 5))$

▲ $\leftrightarrow ((age \geq 3) \wedge (income < 3) \wedge (age \geq 6)) \vee ((age \geq 3) \wedge (income \geq 3) \wedge (age < 5))$

1. Árvores de Decisão – Vantagens

- **Interpretação:** Compreender facilmente a razão subjacente à decisão;
- **Insensível a factores de escala:** Podem ser utilizados diferentes tipos de medidas sem necessidade de normalização; 
- **Definição automática das variáveis mais relevantes** em cada caso;
- **As variáveis mais relevantes aparecem na parte superior da árvore;**
- **As árvores de decisão são consideradas um método não paramétrico:** não há suposições sobre a distribuição das variáveis.

1. Árvores de Decisão – Problemas



2. Árvores de Classificação

2. Árvores de Classificação

Exemplo: Classificação de células

# núcleos	# caudas	Cor	Membrana	Classe
1	1	Clara	Fina	X
2	1	Clara	Fina	X
1	1	Clara	Grossa	X
1	1	Escura	Fina	X
1	1	Escura	Grossa	X
2	2	Clara	Fina	Y
2	2	Escura	Fina	Y
2	2	Escura	Grossa	Y
2	1	Escura	Fina	Z
2	1	Escura	Grossa	Z
1	2	Clara	Fina	Z
1	2	Clara	Grossa	Z

2. Árvores de Classificação

Métrica discriminativa: mede o poder discriminativo de uma determinada variável em relação à variável alvo.

$$\text{Poder discriminativo} = \frac{1}{n} \sum_{i=1} C_i$$

Onde:

- n é o número de observações;
- C_i é o número de observações classificadas com a classe mais frequente da variável alvo, para cada categoria i de uma determinada variável independente.

2. Árvores de Classificação

# núcleos	# caudas	Cor	Membrana	Classe
1	1	Clara	Fina	X
2	1	Clara	Fina	X
1	1	Clara	Grossa	X
1	1	Escura	Fina	X
1	1	Escura	Grossa	X
2	2	Clara	Fina	Y
2	2	Escura	Fina	Y
2	2	Escura	Grossa	Y
2	1	Escura	Fina	Z
2	1	Escura	Grossa	Z
1	2	Clara	Fina	Z
1	2	Clara	Grossa	Z

Usando o # de núcleos:

# núcleos	1	2
X	4	1
Y	0	3
Z	2	2

$$\text{Poder discriminativo} = \frac{4 + 3}{12} = 0.58$$

2. Árvores de Classificação

# núcleos	# caudas	Cor	Membrana	Classe
1	1	Clara	Fina	X
2	1	Clara	Fina	X
1	1	Clara	Grossa	X
1	1	Escura	Fina	X
1	1	Escura	Grossa	X
2	2	Clara	Fina	Y
2	2	Escura	Fina	Y
2	2	Escura	Grossa	Y
2	1	Escura	Fina	Z
2	1	Escura	Grossa	Z
1	2	Clara	Fina	Z
1	2	Clara	Grossa	Z

Usando o # de caudas:

# caudas	1	2
X	5	0
Y	0	3
Z	2	2

$$\text{Poder discriminativo} = \frac{5 + 3}{12} = 0.67$$

2. Árvores de Classificação

# núcleos	# caudas	Cor	Membrana	Classe
1	1	Clara	Fina	X
2	1	Clara	Fina	X
1	1	Clara	Grossa	X
1	1	Escura	Fina	X
1	1	Escura	Grossa	X
2	2	Clara	Fina	Y
2	2	Escura	Fina	Y
2	2	Escura	Grossa	Y
2	1	Escura	Fina	Z
2	1	Escura	Grossa	Z
1	2	Clara	Fina	Z
1	2	Clara	Grossa	Z

Usando a cor:

Cor	Clara	Escura
X	3	2
Y	1	2
Z	2	2

$$\text{Poder discriminativo} = \frac{3 + 2}{12} = 0.41$$

2. Árvores de Classificação

# núcleos	# caudas	Cor	Membrana	Classe
1	1	Clara	Fina	X
2	1	Clara	Fina	X
1	1	Clara	Grossa	X
1	1	Escura	Fina	X
1	1	Escura	Grossa	X
2	2	Clara	Fina	Y
2	2	Escura	Fina	Y
2	2	Escura	Grossa	Y
2	1	Escura	Fina	Z
2	1	Escura	Grossa	Z
1	2	Clara	Fina	Z
1	2	Clara	Grossa	Z

Usando a membrana:

Membrana	Fina	Grossa
X	3	2
Y	2	1
Z	2	2

$$\text{Poder discriminativo} = \frac{3 + 2}{12} = 0.41$$

2. Árvores de Classificação

# núcleos	1	2
X	4	1
Y	0	3
Z	2	2

0.58

# caudas	1	2
X	5	0
Y	0	3
Z	2	2

0.67

Cor	Clara	Escura
X	3	2
Y	1	2
Z	2	2

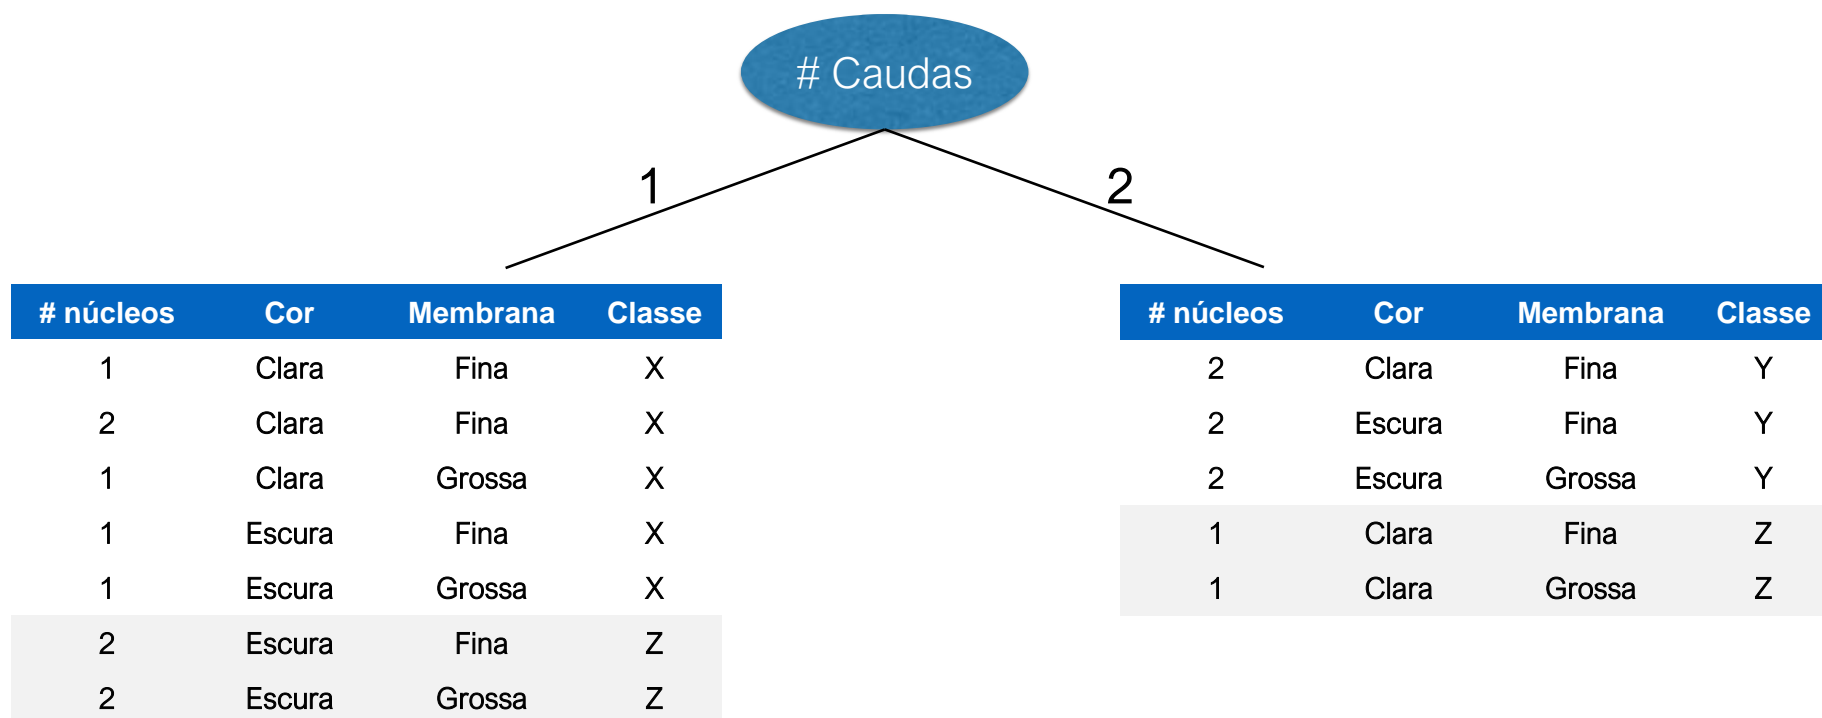
0.41

Membrana	Fina	Grossa
X	3	2
Y	2	1
Z	2	2

0.41

Escolha: # caudas

2. Árvores de Classificação



2. Árvores de Classificação

# núcleos	Cor	Membrana	Classe
1	Clara	Fina	X
2	Clara	Fina	X
1	Clara	Grossa	X
1	Escura	Fina	X
1	Escura	Grossa	X
2	Escura	Fina	Z
2	Escura	Grossa	Z

# núcleos	1	2
X	4	1
Y	0	0
Z	0	2

$P.D = 0.86$


Cor	Clara	Escura
X	3	2
Y	0	0
Z	0	2

$P.D = 0.71$

Membrana	Fina	Grossa
X	3	2
Y	0	0
Z	1	1

$P.D = 0.71$

2. Árvores de Classificação

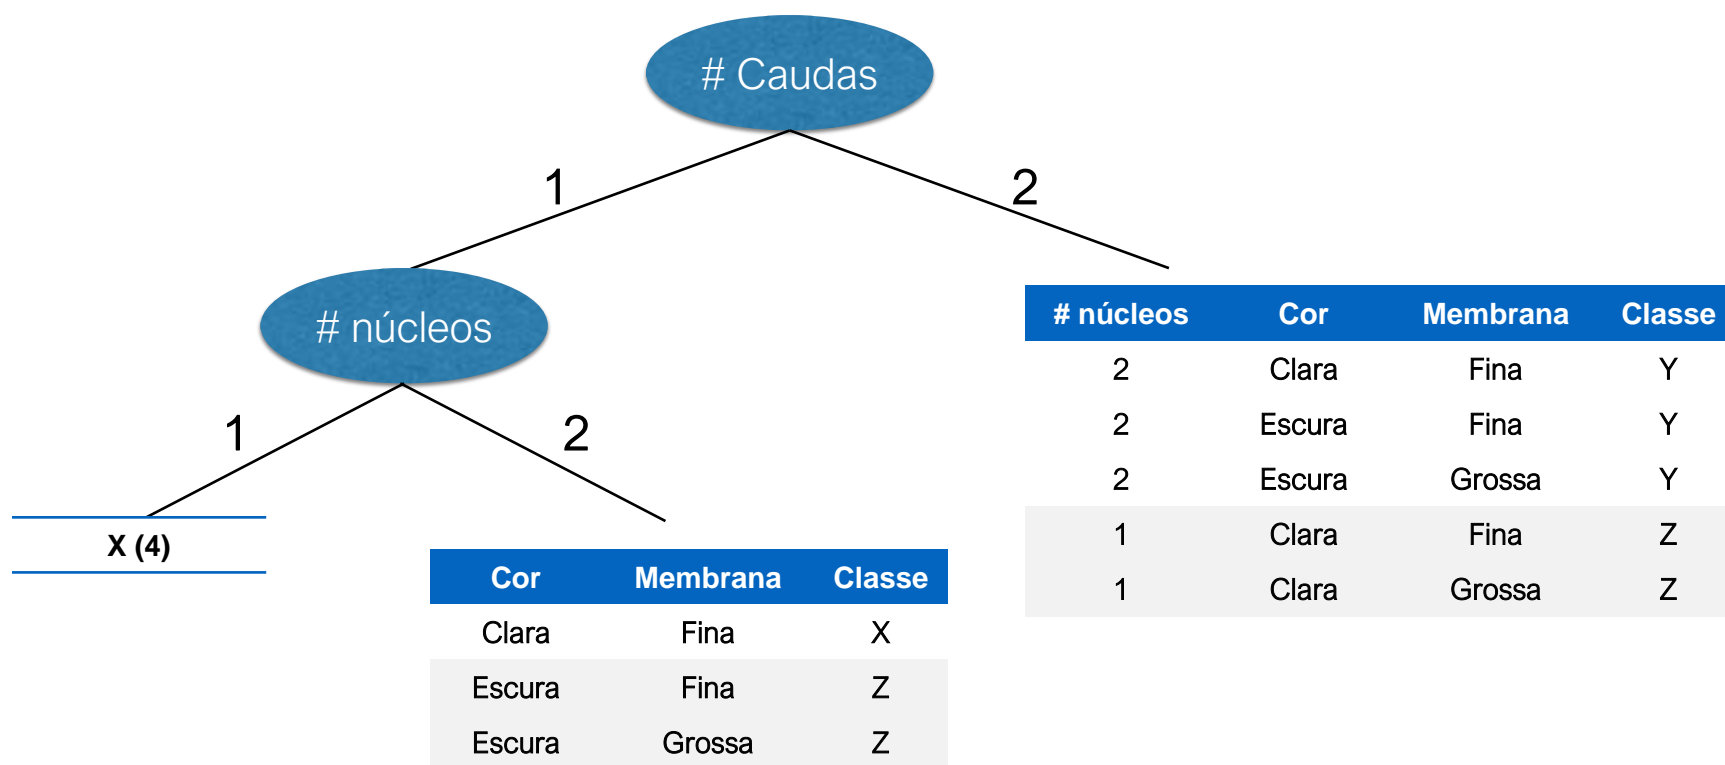


Cor	Membrana	Classe
Clara	Fina	X
Clara	Grossa	X
Escura	Fina	X
Escura	Grossa	X

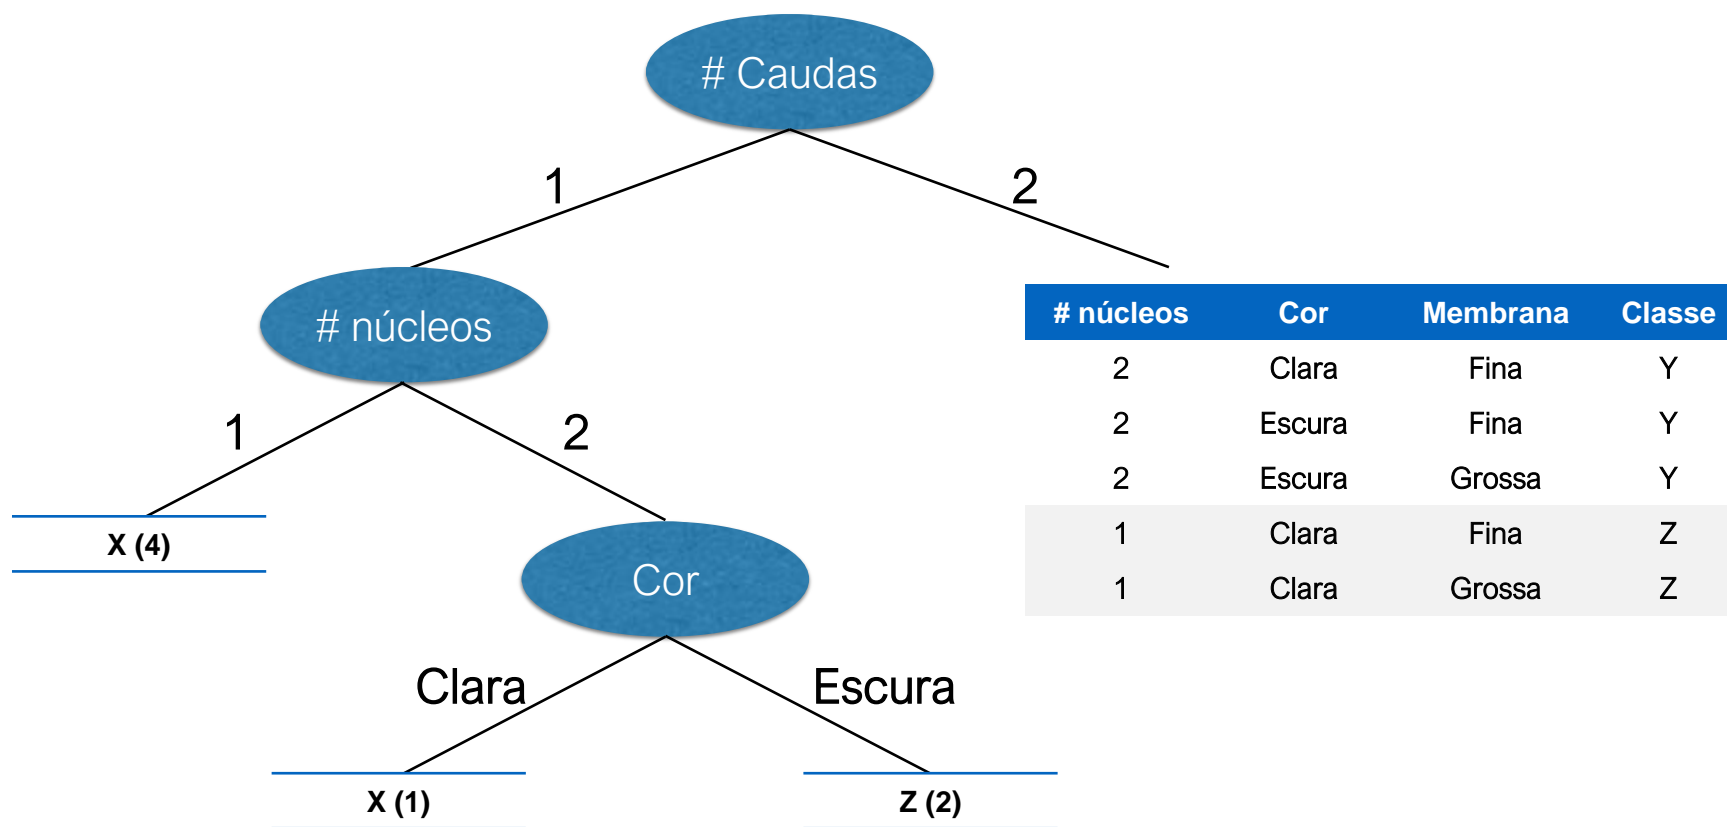
Cor	Membrana	Classe
Clara	Fina	X
Escura	Fina	Z
Escura	Grossa	Z

# núcleos	Cor	Membrana	Classe
2	Clara	Fina	Y
2	Escura	Fina	Y
2	Escura	Grossa	Y
1	Clara	Fina	Z
1	Clara	Grossa	Z

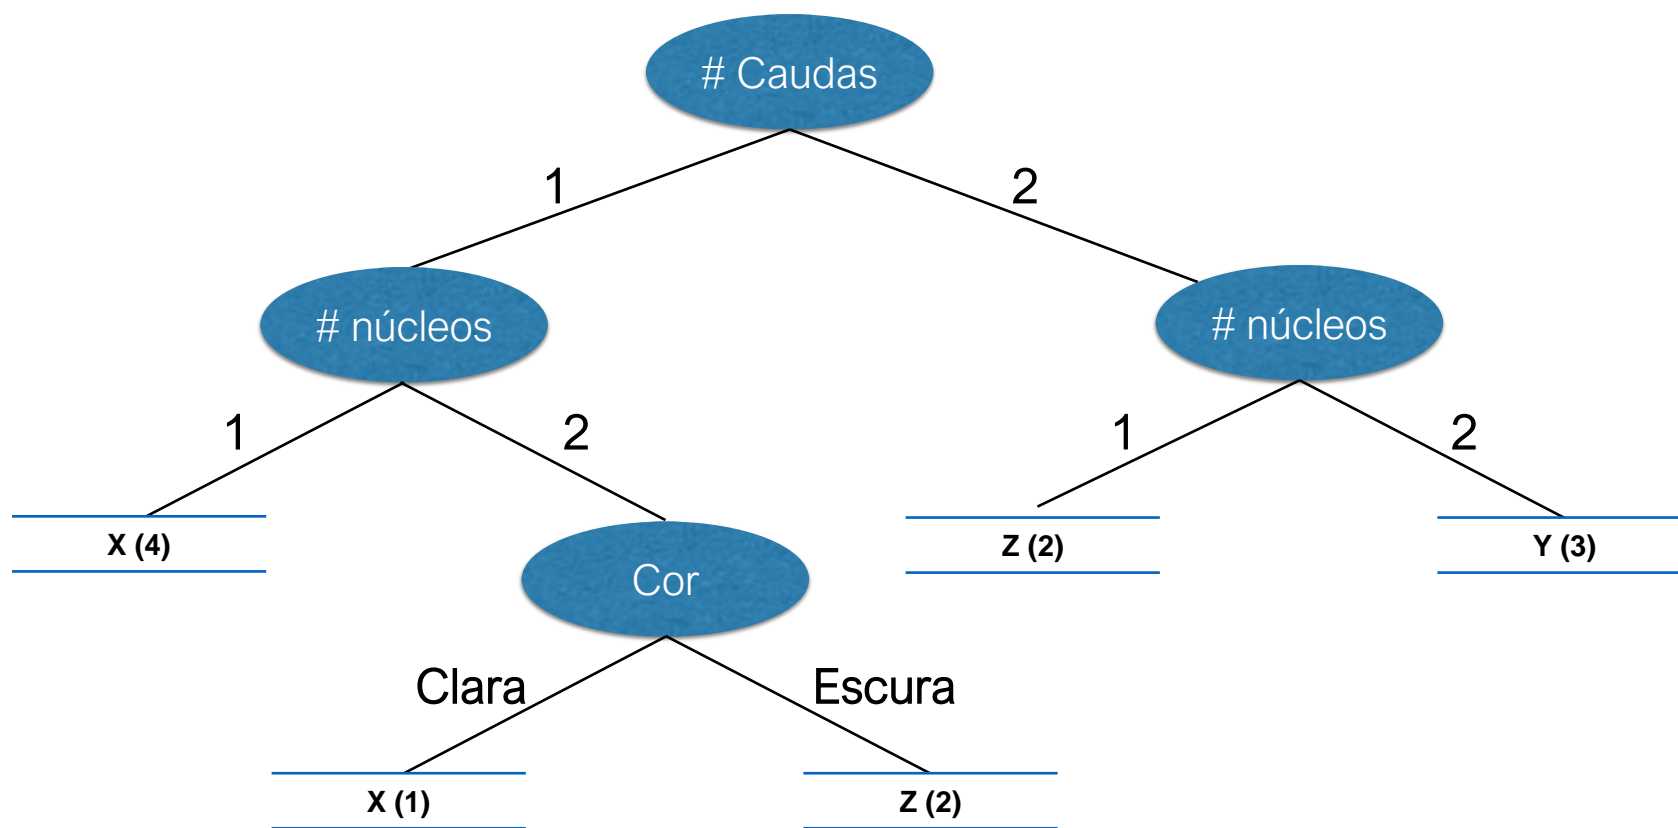
2. Árvores de Classificação



2. Árvores de Classificação



2. Árvores de Classificação

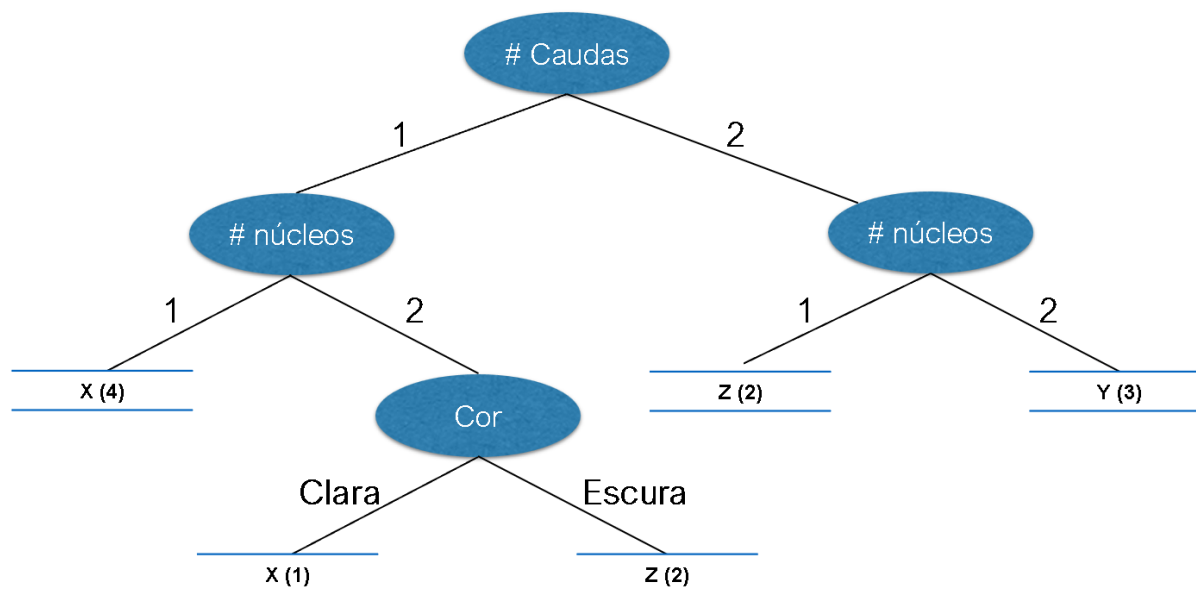


2. Árvores de Classificação

$X \leftrightarrow ((\#caudas = 1) \wedge (\#nucleos = 1)) \vee ((\#caudas = 1) \wedge (\#nucleos = 2) \wedge (cor = Clara))$


$Y \leftrightarrow ((\#caudas = 2) \wedge (\#nucleos = 2))$

$Z \leftrightarrow ((\#caudas = 2) \wedge (\#nucleos = 1)) \vee ((\#caudas = 1) \wedge (\#nucleos = 2) \wedge (cor = Escura))$



2.1 Árvores de Classificação – CART

2.1 Árvores de Classificação – CART

- O algoritmo CART (Classification And Regression Trees) é o algoritmo usado pelo scikit-learn. 
- Utiliza o **Gini index** para medir a “desordem” em cada variável independente:

$$Gini(D) = 1 - \sum_{i=1}^n p_i^2$$

Onde:

- D são os dados de treino para uma determinada classe de uma determinada variável ;
- p_i é a probabilidade de uma observação em D pertencer à classe C_i da variável alvo, estimada por $C_{i,D}/D$;
- $C_{i,D}$ é o número de observações pertencentes à classe C_i e D .

2.1 Árvores de Classificação – CART

- Começamos por calcular o grau de desordem na variável alvo:

$$Gini(D) = 1 - \sum_{i=1}^n p_i^2$$

- Se escolhermos a variável A para dividir o “nó” da árvore em v partições, então o grau de desordem é calculado através de:

$$Gini_A(D) = \sum_{j=1}^v \frac{D_j}{D} \times Gini(D_j)$$

- A partir do Gini index, podemos **calcular o ganho de informação** para uma determinada variável independente A :

$$Gain(A) = Gini(D) - Gini_A(D)$$

2.1 Árvores de Classificação – CART

Exemplo: compra de um computador

idade	rendimento	estudante	rating_crédito	compra_pc	→ Variável dependente
<= 30	elevado	não	médio	não	
<= 30	elevado	não	excelente	não	
[31, ...,40]	elevado	não	médio	sim	
> 40	médio	não	médio	sim	
> 40	baixo	sim	médio	sim	
> 40	baixo	sim	excelente	não	
[31, ...,40]	baixo	sim	excelente	sim	
<= 30	médio	não	médio	não	
<= 30	baixo	sim	médio	sim	
> 40	médio	sim	médio	sim	
<= 30	médio	sim	excelente	sim	
[31, ...,40]	médio	não	excelente	sim	
[31, ...,40]	elevado	sim	médio	sim	
> 40	médio	não	excelente	não	

2.1 Árvores de Classificação – CART

$$Gini(D) = 1 - \sum_{i=1}^n p_i^2$$

compra_pc	
sim	não
9	5

$$Gini_{pc}(D) = Gini(9, 5) = 1 - \left(\frac{9}{14}\right)^2 - \left(\frac{5}{14}\right)^2 = 0.459$$



2.1 Árvores de Classificação – CART

Calculando o Gini associado à variável **idade**:

idade	sim	não	Total	Gini	
≤ 30	2	3	5	0.48	$Gini_{\leq 30}(D) = Gini(2, 3) = 1 - (2/5)^2 - (3/5)^2 = 0.48$
$[31, \dots, 40]$	4	0	4	0	$Gini_{[31, \dots, 40]}(D) = Gini(4, 0) = 1 - (4/4)^2 - (0/4)^2 = 0$
> 40	3	2	5	0.48	$Gini_{> 40}(D) = Gini(3, 2) = 1 - (3/5)^2 - (2/5)^2 = 0.48$

$$Gini_A(D) = \sum_{j=1}^v \frac{D_j}{D} \times Gini(D_j)$$

$$Gini_{idade}(D) = \frac{5}{14} Gini_{\leq 30}(3, 2) + \frac{4}{14} Gini_{[31, \dots, 40]}(4, 0) + \frac{5}{14} Gini_{> 40}(3, 2) = 0.343$$

2.1 Árvores de Classificação – CART

$$Gain(A) = Gini(D) - Gini_A(D)$$

Assim, o ganho de informação na variável **idade** é:

$$Gain(idade) = Gini_{pc}(D) - Gini_{idade}(D) = 0.459 - 0.343 = 0.116$$



Se repetirmos o mesmo para as restantes variáveis:

$$Gain(rendimento) = 0.459 - 0.440 = 0.019$$

$$Gain(estudante) = 0.459 - 0.368 = 0.091$$

$$Gain(crédito) = 0.459 - 0.429 = 0.03$$



Idade é a variável com o maior ganho de informação, pelo que começamos com essa variável na segmentação da árvore.

2.1 Árvores de Classificação – CART

- Em alternativa ao Gini index, podemos usar a Entropy:

$$Entropy(D) = - \sum_{i=1}^n p_i \log_2(p_i)$$



- Se escolhermos a variável A para dividir o “nó” da árvore em v partições, então o grau de desordem é calculado através de:

$$Entropy_A(D) = \sum_{j=1}^v \frac{D_j}{D} \times Entropy(D_j)$$

- A partir do Gini index, podemos **calcular o ganho de informação** para uma determinada variável independente A :

$$Gain(A) = Entropy(D) - Entropy_A(D)$$

2.1 Árvores de Classificação – CART

$$Entropy(D) = - \sum_{i=1}^n p_i \log_2(p_i)$$

compra_pc	
sim	não
9	5

$$Entropy_{pc}(D) = E(9, 5) = -\frac{9}{14} \log_2 \left(\frac{9}{14} \right)^2 - \frac{5}{14} \log_2 \left(\frac{5}{14} \right)^2 = 0.940$$

2.1 Árvores de Classificação – CART

Calculando a Entropy associado à variável **idade**:

idade	sim	não	Total	Gini
≤ 30	2	3	5	0.48
$[31, \dots, 40]$	4	0	4	0
> 40	3	2	5	0.48

$$Entropy_{\leq 30}(D) = E(2, 3) = -(2/5)\log_2(2/5) - (3/5)\log_2(3/5) = 0.971$$

$$Gini_{[31, \dots, 40]}(D) = E(4, 0) = -(4/4)\log_2(4/4) - (0/4)\log_2(0/4) = 0$$

$$Gini_{> 40}(D) = E(3, 2) = -(3/5)\log_2(3/5) - (2/5)\log_2(2/5) = 0.971$$

$$Entropy_A(D) = \sum_{j=1}^v \frac{D_j}{D} \times Entropy(D_j)$$

$$Entropy_{idade}(D) = \frac{5}{14} E_{\leq 30}(3, 2) + \frac{4}{14} E_{[31, \dots, 40]}(4, 0) + \frac{5}{14} E_{> 40}(3, 2) = 0.694$$

2.1 Árvores de Classificação – CART

$$Gain(A) = Entropy(D) - Entropy_A(D)$$

Assim, o ganho de informação na variável **idade** é:

$$Entropy(idade) = E_{pc}(D) - E_{idade}(D) = 0.940 - 0.694 = 0.246$$

Se repetirmos o mesmo para as restantes variáveis:

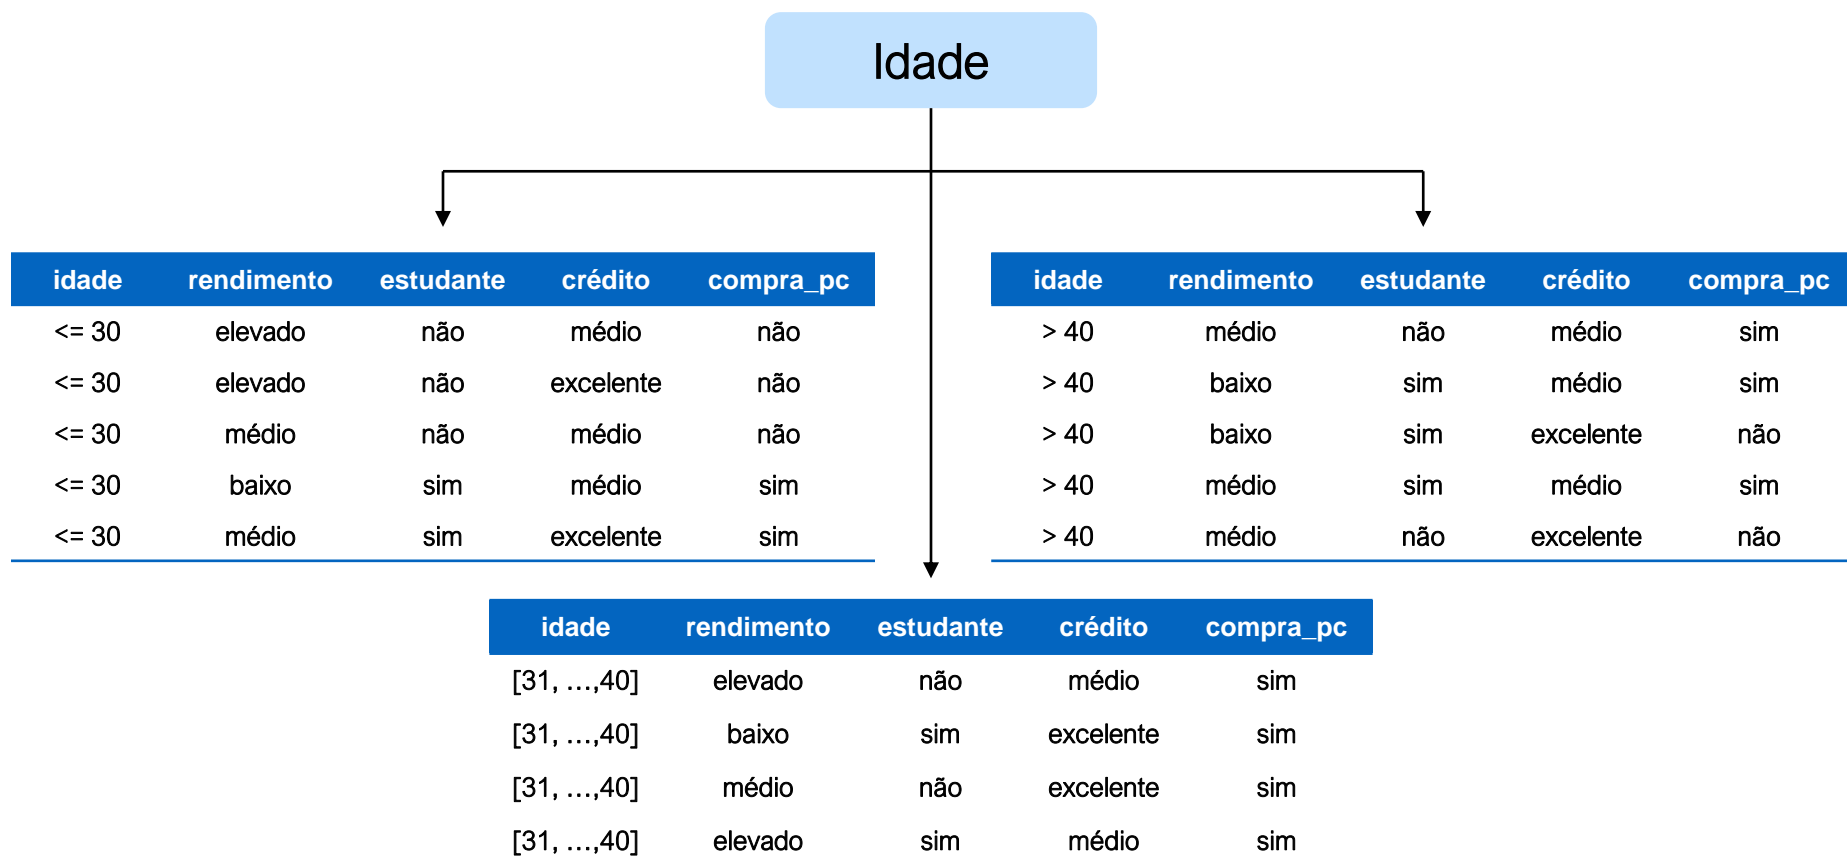
$$Entropy(rendimento) = 0.029$$

$$Entropy(estudante) = 0.151$$

$$Entropy(crédito) = 0.048$$

Idade continua a ser a variável com o maior ganho de informação, pelo que começamos com essa variável na segmentação da árvore.

2.1 Árvores de Classificação – CART



2.1 Árvores de Classificação – CART

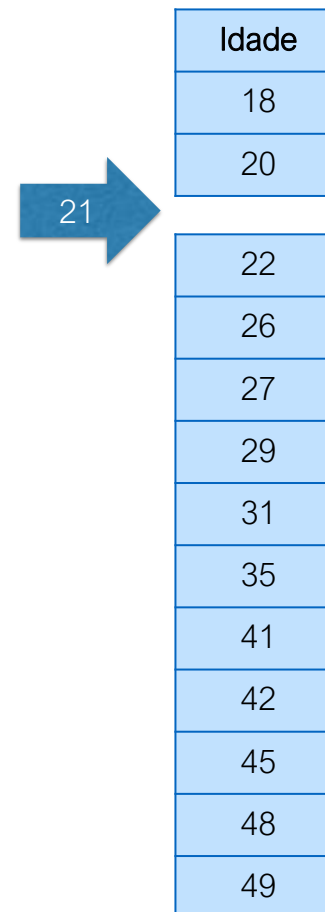
- Na verdade, a **árvore de decisão CART apenas cria ramos binários** para uma determinada variável.
- Ou seja, no caso da variável Idade, não seriam criados 3 ramos, mas sim apenas 2... esta é uma das limitações deste algoritmo.
- Assim, antes de iniciarmos o treino do modelo, **devemos transformar as variáveis categóricas em variáveis numéricas**, por exemplo, através de one-hot encoding, obrigando a árvore a criar ramos binários.
- Algoritmos como o ID3, C4.5, C5 permitem a criação de mais de 2 ramos!

2.1 Árvores de Classificação – CART

Mas e se a variável Idade fosse numérica?

Então seria necessário determinar o melhor ponto de corte:

- Ordenar os valores da variável;
- Cada ponto médio entre cada par de valores adjacentes é um possível ponto de corte;
- Avaliar a medida de grau de desordem (Gini, Entropy, etc.) para as partições separadas por cada ponto de corte.
- Escolher o ponto de corte que produza o menor grau de desordem.
- Este grau de desordem (e ganho de informação) é comparado com o das restantes variáveis, como visto anteriormente.




Idade
18
20
21
22
26
27
29
31
35
41
42
45
48
49

2.2 Árvores de Regressão

2.2 Árvores de Regressão

- Num problema de regressão, há alguns problemas que são fáceis de ajustar utilizando uma regressão linear:



2.2 Árvores de Regressão



2.2 Árvores de Regressão

- Para certos conjuntos de dados, devemos utilizar outros métodos que não a utilização de linhas rectas para fazer previsões.
- Uma opção é a árvore de regressão!
- Uma árvore de regressão é um tipo de árvore de decisão em que **cada “leaf node” representa um valor numérico e não uma categoria discreta** como nas árvores de decisão de classificação.


2.2 Árvores de Regressão

- Quando temos mais de 2 preditores, tais como a idade, o número de filhos e o número de meses como cliente, prever o dinheiro montante através de um gráfico é muito difícil, se não impossível...

Idade	#Filhos	#Meses como Cliente	...	Montante gasto
18	0	1	...	5
22	1	1	...	7
23	0	3	...	6
27	2	2	...	68
34	3	2	...	72
38	2	3	...	69
43	1	2	...	77
45	0	1	...	48
48	3	2	...	42
53	2	1	...	16
57	3	3	...	18
64	1	2	...	14

2.2 Árvores de Regressão

- A primeira coisa a fazer, tal como nas árvores de classificação, é decidir qual a variável com menos “grau de desordem” para começar a utilizar na árvore.
- Mas como decidimos qual o ponto de corte a usar nas variáveis, de modo a calcular esse “grau de desordem”?



Para cada variável, ordenamos os valores e testamos diferentes pontes de corte, calculando o erro total da previsão (média da variável alvo) para cada grupo:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y - \hat{y})^2$$

Em alternativa do MSE, o MAE pode ser usado.



2.2 Árvores de Regressão

- Começando na variável **Idade**:

Idade	Montante gasto (y)
18	5
22	7
23	6
27	68
34	72
...	..
57	18
64	14

Se o ponto de corte for Idade ≤ 20 :

- 1º grupo de observações:

$$\bar{y} = 5$$

$$MSE(Idade \leq 20) = \frac{1}{1} (5 - 5)^2 = 0$$

- 2º grupo de observações:



$$\bar{y} = \frac{7 + 6 + \dots + 14}{11} = 39.7$$

$$MSE(Idade > 20) = \frac{1}{11} ((7 - 39.7)^2 + (6 - 39.7)^2 + \dots + (14 - 39.7)^2) = 733.3$$

$$TOTAL\ MSE = 0 + 733.3 = 733.3$$

2.2 Árvores de Regressão

Se o ponto de corte for Idade ≤ 20 :



2.2 Árvores de Regressão

- Começando na variável **Idade**:

Idade	Montante gasto (y)
18	5
22	7
23	6
27	68
34	72
...	...
57	18
64	14

Se o ponto de corte for $Idade \leq 22.5$:

- 1º grupo de observações:

$$\bar{y} = 6$$

$$MSE(Idade \leq 22.5) = \frac{1}{2}((5 - 6)^2 + (7 - 6)^2) = 1$$

- 2º grupo de observações:

$$\bar{y} = \frac{6 + 68 + \dots + 14}{10} = 43.2$$



$$MSE(Idade > 22.5) = \frac{1}{10}((6 - 43.2)^2 + (68 - 43.2)^2 + \dots + (14 - 43.2)^2) = 688.8$$

$$TOTAL\ MSE = 1 + 688.8 = 689.8$$



2.2 Árvores de Regressão

Se o ponto de corte for Idade ≤ 22.5 :



2.2 Árvores de Regressão

- Começando na variável **Idade**:

Idade	Montante gasto (y)
18	5
22	7
23	6
27	68
34	72
...	...
57	18
64	14

Se o ponto de corte for Idade ≤ 25 :

- 1º grupo de observações:

$$\bar{y} = 6$$

$$MSE(Idade \leq 25) = \frac{1}{3}((5 - 6)^2 + (7 - 6)^2 + (6 - 6)^2) = 0.7$$

- 2º grupo de observações:



$$\bar{y} = \frac{68 + 72 + \dots + 14}{10} = 47.1$$

$$MSE(Idade > 25) = \frac{1}{9}((68 - 47.1)^2 + (72 - 47.1)^2 + \dots + (14 - 47.1)^2) = 596.3$$

$$TOTAL\ MSE = 0.7 + 596.3 = 597.0$$

2.2 Árvores de Regressão


Se o ponto de corte for Idade ≤ 25 :



2.2 Árvores de Regressão

- Começando na variável **Idade**:

Ponto de corte para Idade	<i>TOTAL MSE</i>
≤ 20.0	733.3
≤ 22.5	689.8
≤ 25.0	597.0
≤ 30.5	1333.0
≤ 36.0	1558.1
≤ 40.5	1526.6
≤ 44.0	1265.0
≤ 46.5	1056.8
≤ 50.5	828.0
≤ 55.0	816.2
≤ 60.5	782.1



2.2 Árvores de Regressão

- E para a variável **#Filhos**:

#Filhos	Montante gasto
0	5
1	7
0	6
2	68
3	72
2	69
1	77
0	48
3	42
2	16
3	18
1	14



Ponto de corte para #Filhos	<i>TOTAL MSE</i>
≤ 0.5	1155.8
≤ 1.5	1301.1
≤ 2.5	1321.6

2.2 Árvores de Regressão

- E para a variável **#Meses Cliente**:

#Meses	Montante gasto
1	5
1	7
3	6
2	68
2	72
3	69
2	77
1	48
2	42
1	16
3	18
2	14



Ponto de corte para #Meses	<i>TOTAL MSE</i>
≤ 1.5	1056.7
≤ 2.5	1501.3

2.2 Árvores de Regressão

- Comparando o erro total usando o melhor ponto de corte para cada variável:

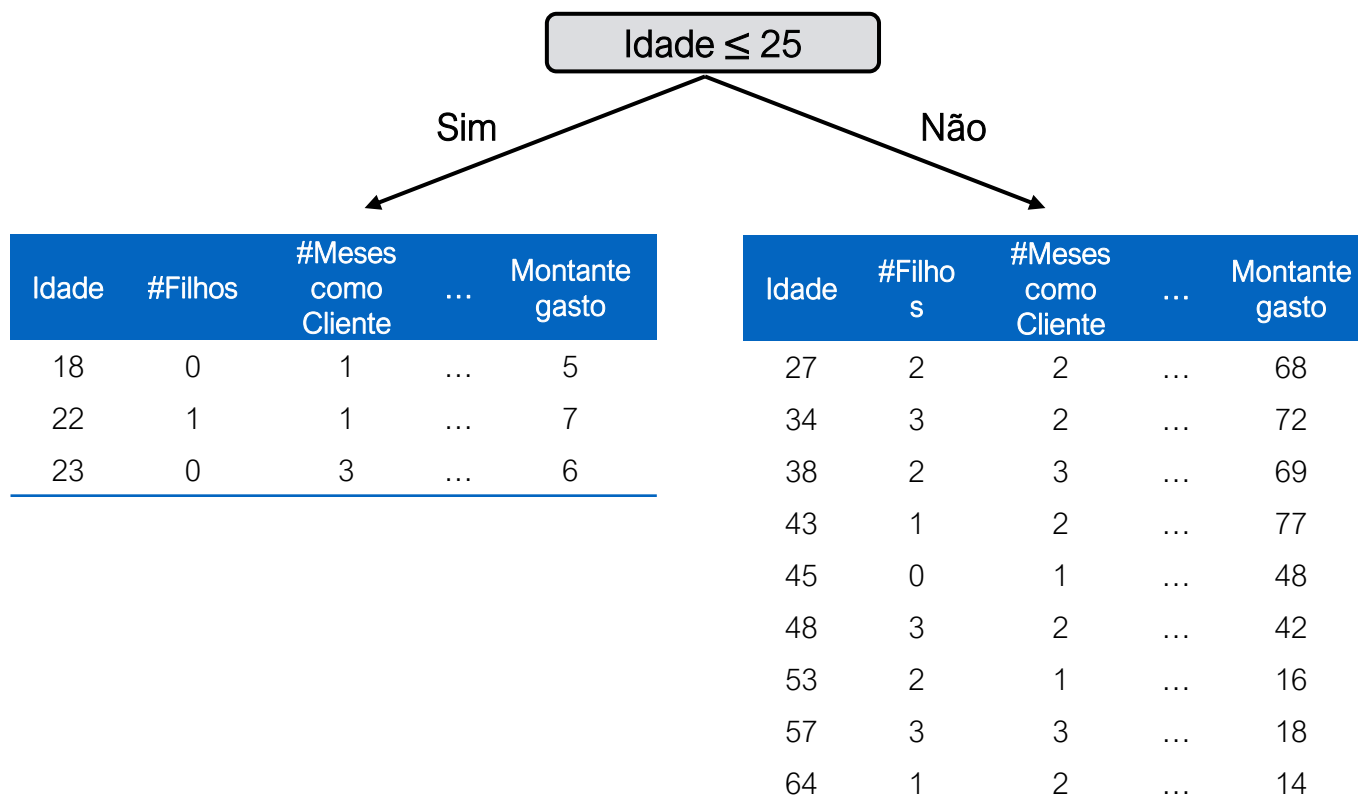
Ponto de corte para Idade	<i>TOTAL MSE</i>
≤ 20.0	733.3
≤ 22.5	689.8
≤ 25.0	597.0
≤ 30.5	1333.0
≤ 36.0	1558.1
≤ 40.5	1526.6
≤ 44.0	1265.0
≤ 46.5	1056.8
≤ 50.5	828.0
≤ 55.0	816.2
≤ 60.5	782.1

Ponto de corte para #Filhos	<i>TOTAL MSE</i>
≤ 0.5	1155.8
≤ 1.5	1301.1
≤ 2.5	1321.6

Ponto de corte para #Meses	<i>TOTAL MSE</i>
≤ 1.5	1056.7
≤ 2.5	1501.3

2.2 Árvores de Regressão

- A primeira variável a ser usada é **Idade com o ponto de corte ≤ 25** :



2.2 Árvores de Regressão - Overfitting

- Para evitar overfitting, podemos definir um número mínimo de samples, abaixo do qual uma determinada ramificação deixa de ser segmentada.
- Por exemplo, se definissemos $min_samples = 7$, o ramo da esquerda terminaria e a 'lead node' $Idade \leq 25$ passa a ter um valor previsto de montante gasto de 6!
- Outra forma de evitar overfitting seria definindo um nível máximo de profundidade, por exemplo, se $max_depth = 1$, a árvore terminaria.

Obrigado!