



Módulo 9 – Sessão 2

# INTRODUCTION TO NETWORKS

TUTORA

Carla Cardoso

Freelancer AI Manager

10 de abril 2025




1

## AGENDA



NEURAL NETWORKS



DEEP LEARNING



EXEMPLO APLICAÇÕES



RECOMENDAÇÕES

2



## DEEP LEARNING: DEFINIÇÃO

EDIT.

Os modelos de **Deep learning** são modelos baseados nos modelos de Artificial Neural Networks (ANNs). O adjetivo "deep" (profundo) refere-se à multiplicidade de camadas destas redes.

Tal como nas ANN, os modelos de **Deep Learning** podem ser usados para problemas **Supervisionados** e **não-Supervisionados**.

O 2 tipos de algoritmos de **Deep Learning** mais usados são as **RNN** e as **CNN**, que falaremos seguidamente,



3

## DEEP LEARNING: GAME CHANGER

EDIT.

Os modelos de Deep Learning, ainda que baseados em Redes Neurais, têm uma **complexidade** muito mais elevada, e por isso uma assertividade nunca antes vista. Essa complexidade foi possível de alcançar sobretudo devido:

- ✓ Incremento na capacidade de **processamento**
- ✓ **Informação** disponível
- ✓ Desenvolvimento novas **arquiteturas**

Estes benefícios foram sobretudo sentidos no processamento de dados complexos, como **texto**, **áudio** e **imagem**.

Seguidamente vamos ver alguns desses modelos.

## Exemplo para Computer Vision

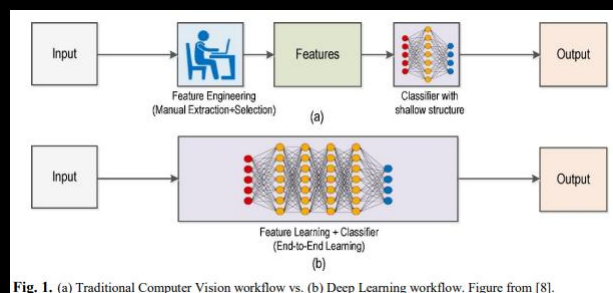


Fig. 1. (a) Traditional Computer Vision workflow vs. (b) Deep Learning workflow. Figure from [8].


4

## DEEP LEARNING: RECURRENT NEURAL NETWORK

EDIT.

Falamos até agora da arquitetura **Feedforward**, arquitecturas onde todos os nós de uma camada estão ligados aos nós da camada seguinte (full connection) e em apenas uma direção.

No caso das **Recurrent Neural Networks** (RNN), essa limitação não se verifica. Estas redes são especialmente úteis para dados sequenciais ou series temporais.




5

## DEEP LEARNING: LONG SHORT-TERM MEMORY

EDIT.

Nesta arquitetura, por forma a incorporar eventos sequenciais, o output de um evento instanciado em  $t$  é influenciado pelo output instanciado em  $t-1$ . As RNN são tipicamente utilizadas como **suporte de outras arquiteturas**, como por exemplo as **LSTM** e os **Transformers**.

A **Long short-term memory** (LSTM) é uma arquitetura é muito popular, e veio resolver um dos problemas das RNN relacionado com o *vanishing e exploding gradient* – sub ou sobrevalorização eventos passados.



Para remediar isso, os LSTMs possuem “células” nas camadas escondidas da rede, que possuem três gates (portas) – **input gate**, **output gate** e **forget gate** (esquecimento).

Cada uma destas portas pode estar ativa ou inativa, dependendo da relevância da informação.

6

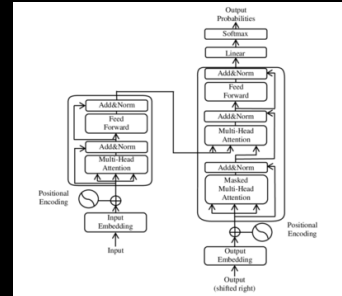
## DEEP LEARNING: TRANSFORMERS

EDIT.

Outra arquitetura que beneficia das RNN é a arquitetura **Transformers**, que falamos no Capítulo 1, e que foi revolucionária no processamento de informação não estruturada: texto, som e imagem.

Estes modelos transformam uma **sequência de entrada** (ex.: pergunta) numa **sequência de saída** (ex.: resposta).

Para isso, os modelos aprendem o **contexto** e fazem o **tracking das relações entre os componentes** da sequência. Por exemplo, considerando a pergunta: "Qual é a cor do céu?" o modelo irá usar a representação matemática interna que identifica a relevância e a relação entre as palavras "cor", "céu" e "azul", e com isso gerar o resultado: "O céu é azul".



As arquiteturas RNN, LSTMs e Transformers são a base dos modelos de **Generative AI**, que por sua vez suportam ferramentas como o ChatGPT.

7

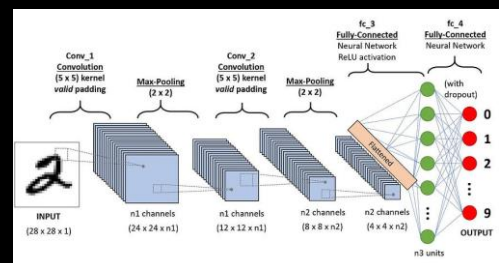
## DEEP LEARNING: CONVOLUTIONAL NEURAL NETWORK

EDIT.

As **Convolutional Neural Networks** ou **CNN** são redes neurais do tipo **Feedforward** usadas tipicamente para processamento de dados de imagens.

Trata-se de um algoritmo que recebe uma imagem de entrada, atribuir **importâncias diferentes** a diferentes aspetos/objetos na imagem, o que lhe permite diferenciar uns dos outros.

Cada um desses aspetos é trabalhado numa CNN, e depois serve de **input a uma rede neuronal**.



Estas redes foram inspiradas na organização do **Córtex Visual**, onde neurónios individuais respondem a estímulos apenas numa região restrita do campo visual conhecida como **Receptive Field**. Finalmente, ao juntamos na nossa mente todos campos, sobrepostos por forma a cobrir toda a área visual, ganhamos a perspetiva total da imagem.

8


## DEEP LEARNING: CONVOLUTIONAL NEURAL NETWORK

EDIT


Este tipo de redes permitem realizar as seguintes ações sobre imagens:

**Classification**

CAT

**Classification  
+ Localization**

CAT

**Object Detection**

CAT, DOG, DUCK

**Instance  
Segmentation**

CAT, DOG, DUCK

## DEEP LEARNING: CONVOLUTIONAL NEURAL NETWORK

EDIT


Este tipo de redes permitem realizar as seguintes ações sobre imagens:

**Classification**

CAT

**Classification  
+ Localization**

CAT

**Object Detection**

CAT, DOG, DUCK


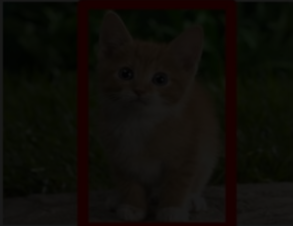
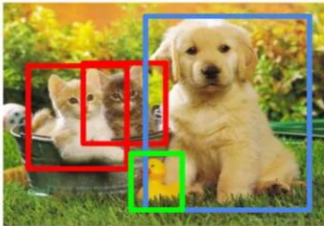

**Instance  
Segmentation**

CAT, DOG, DUCK

## DEEP LEARNING: CONVOLUTIONAL NEURAL NETWORK

EDIT.

Este tipo de redes permitem realizar as seguintes ações sobre imagens:

Classification	Classification + Localization	Object Detection	Instance Segmentation
			
CAT	CAT	CAT, DOG, DUCK	CAT, DOG, DUCK


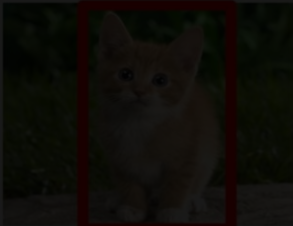
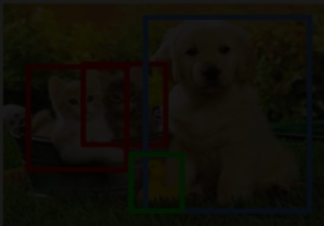

DATA SCIENCE & BUSINESS ANALYTICS      Módulo 9 – Introduction to Networks – Sessão 2      11

11

## DEEP LEARNING: CONVOLUTIONAL NEURAL NETWORK

EDIT.

Este tipo de redes permitem realizar as seguintes ações sobre imagens:

Classification	Classification + Localization	Object Detection	Instance Segmentation
			
CAT	CAT	CAT, DOG, DUCK	CAT, DOG, DUCK

DATA SCIENCE & BUSINESS ANALYTICS      Módulo 9 – Introduction to Networks – Sessão 2      12


12

## AGENDA

EDIT.



REDES NEURONAIS



DEEP LEARNING



EXEMPLO APLICAÇÕES



RECOMENDAÇÕES

13

## EXEMPLO APLICAÇÕES: HEALTHCARE

EDIT.


Os benefícios do uso de **Deep Learning** na medicina e têm sido vastos e determinantes para a evolução que se tem verificado nesta área.

Alguns exemplos:

- Apoio no **diagnóstico de doenças**: identificação precoce de células cancerígenas, deteção de variações em eletrocardiogramas, etc.
- **Sugestão de tratamento**: com base nos sintomas, histórico médico e medicação atual do paciente, propõe tratamento
- **Desenvolvimento de medicamentos**
- **Medicina personalizada**: algoritmos que usam informação dos genes para prever resposta a determinados princípios ativos

#### RADIOLOGISTS USE DEEP LEARNING TO FIND SIGNS OF COVID-19 IN CHEST X-RAYS

/ RADIOLOGISTS USE DEEP LEARNING



MAY 26, 2020 Radiologists use deep learning to find signs of COVID-19 in chest x-rays

14



## EXEMPLO APLICAÇÕES: SETOR FINANCEIRO

EDIT.



No mercado financeiro os benefícios também são vários.

Alguns exemplos:

- **Deteção de Fraude:** estes modelos têm a capacidade de analisar elevados volumes de dados permitindo encontrar padrões anómalos, tipicamente associados com fraude
- **Avaliação de Risco:** Análise de padrões históricos dos mercados para identificar tendências e prever movimentos, permitindo aos investidores tomarem decisões mais informadas
- **Estratégias de Investimento:** apoio na definição de estratégias de investimento com recurso a simulações e a previsão de cenários mais prováveis

15


## EXEMPLO APLICAÇÕES: TRANSPORTES

EDIT.

Na área dos transportes, o maior impacto, ou pelo menos os mais falado, está relacionado com os carros autónomos, mas os benefícios / aplicações de **Deep Learning** não ficam por aí.

Alguns exemplos:

- **Carros autónomos:** ao terem a capacidade de processar enormes volumes de dados, estes algoritmos conseguem “interpretar” o contexto em que se inserem e tomar decisões, mesmo em situações complexas
- **Logística transportes públicos:** sobretudo uteis na otimização de rotas e previsão de utilizadores e de tempo de chegada
- **Aplicações rotas:** algoritmos ajudam a prever riscos de aglomeração de veículos e sugerir rotas alternativas



16



## EXEMPLO APLICAÇÕES: TRANSPORTES

EDIT.



17

## EXEMPLO APLICAÇÕES: ASSISTENTES VIRTUAIS

EDIT.



Nos últimos anos, uma das **inovações em AI mais marcante** foi a dos assistentes virtuais. Siri, Alexa, Cortana e ChatGPT.

O desenvolvimento foi especialmente relevante nos últimos anos com o GenAI e neste momento é possível incorporar assistentes virtuais **via API** em praticamente todas as aplicações.

Alguns exemplos de uso de assistentes AI:

- **Escrita** de emails, relatórios, artigos, ...
- **Organização** calendário, planejar tarefas, ...
- **Suporte ao Cliente**
- Geração, validação, identificação de fragilidades de **código de programação**, ...

DATA SCIENCE &amp; BUSINESS ANALYTICS


Módulo 9 – Introduction to Networks – Sessão 2

18

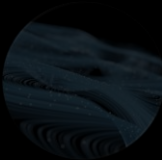
18

AGENDA


EDIT.




REDES NEURONAIS



DEEP LEARNING



PRINCIPAIS APLICAÇÕES



RECOMENDAÇÕES

DATA SCIENCE & BUSINESS ANALYTICS

Módulo 9 – Introduction to Networks – Sessão 2

19

19

RECOMENDAÇÕES

EDIT.

REQUISITOS

DATA SCIENCE & BUSINESS ANALYTICS

Módulo 9 – Introduction to Networks – Sessão 2

20

20

## REQUISITOS: DADOS

EDIT.



Apesar de todas as vantagens dos modelos de **Deep Learning** eles não devem ser usados para a resolução de todos os problemas devido aos seus requisitos / limitações.

- **Dados:** uma das características destes modelos é a necessidade de um elevado número de exemplos para treino. O fato de tipicamente lidarem com dados não estruturados, como imagens, áudio ou texto, com elevada variabilidade, obriga ao uso de *datasets* com milhares ou até milhões de exemplos.

Por exemplo, o **ChatGPT** usou 176 *billions* ( $10^9$ ) enquanto o **GPT-4** necessitou de **~1,7 trillions** ( $10^{12}$ ) de **parâmetros**.

DATA SCIENCE &amp; BUSINESS ANALYTICS

Módulo 9 – Introduction to Networks – Sessão 2

21

21

## REQUISITOS : HARDWARE / TEMPO

EDIT.

A volumetria de dados obriga a uma elevada capacidade de processamento e, a sua característica de aprendizagem iterativa, implica um longo processo de aprendizagem.

- **Hardware:** os requisitos de hardware, sobretudo GPUs, necessárias para treinar estes modelos é muito elevada
- **Tempo:** apesar da grande capacidade do hardware, o tempo para treino destes modelos é muito elevado

Por exemplo, o **GPT-4**, foi treinado usando **~25,000 Nvidia A100** durante **~100 dias**.



DATA SCIENCE &amp; BUSINESS ANALYTICS

Módulo 9 – Introduction to Networks – Sessão 2

22

22

## REQUISITOS : ENERGIA



Como resultado do hardware necessário e do tempo de treino, temos o consumo energético.

- **Energia:** a dimensão dos *datasets* de treino e o número de parâmetros obrigam ao recurso de um elevado número de GPUs a correr durante um período de tempo considerável
- **Poluição:** apesar de estarmos a falar de elevados consumos energéticos, por forma a minimizar os impactos, é importante escolher *datacentres* que usem maioritariamente fontes de energia renovável

Olhando novamente para o **GPT-4**, temos que o seu treino implicou um custo energético de **~50GWh** (↔ consumo energético de ~2,700 famílias/ano).

23

## RECOMENDAÇÕES



## LIMITAÇÕES

24



## LIMITAÇÕES : EXPLICABILIDADE



A elevada complexidade destes algoritmos tem como principal limitação a dificuldade em explicar os seus resultados.

A falta de explicabilidade leva a vários problemas:

- **Transparência:** sem acesso a como os dados de treino estão a ser usados, é muitas vezes complicado perceber em que fatores está o modelo a focar-se (ex.: cão vs. lobo)
- **Controlo do output:** ainda que os modelos de ML “apenas” repliquem padrões dos dados, não é do interesse social replicar preconceitos e enviesamentos de decisões, algo que é muito complexo de controlar nestes modelos
- **Alucinações:** no caso de GenAI, dado a base da resposta ser probabilística, há o risco das respostas não fazerem sentido

## LIMITAÇÕES : DEPENDENCIA DOS DADOS



Apesar do elevado número de parâmetros e capacidade computacional, é a qualidade dos dados de treino, e a sua representatividade, que mais contribuem para a qualidade do modelo.

*“Garbage in garbage out”*

Não basta ter bons engenheiros de *Deep Learning*, continuam a ter um papel extremamente relevante os:

- **Especialistas de negócio:** melhor conhecem o negócio
- **Data Engineers:** melhor conhecem as fontes de dados
- **Data Scientists:** melhor fazem a ponte entre os diferentes especialistas, e melhor preparam os dados para os modelos



# RISCOS

27



Quando usamos soluções de AI no nosso dia-a-dia, podemos ficar com a **sensação que não somos responsáveis** pelo output dos modelos que usamos, especialmente quando baseados em **Deep Learning**, pois não conseguimos prever / controlamos esse mesmo output.

Mas a realidade é bem diferente.

Legalmente, sempre que usamos o output de um modelo em determinada tarefa, somos **nós os responsáveis**, mesmo quando usamos APIs de parceiros para gerar o output, (ex.: GPT-4).

**A responsabilidade é sempre do utilizador dos outputs.**

28



## RISCOS : RESPONSABILIDADE



Por exemplo: termos de utilização OpenAI:

- **"Ownership of Content.** As between you and OpenAI, and to the extent permitted by applicable law, you (a) retain your ownership rights in Input and (b) **own the Output.** We hereby assign to you all our right, title, and interest, if any, in and to Output."
- **"Limitation of Liability:** neither we nor any of our affiliates or licensors will be liable for any indirect, incidental, special, consequential, or exemplary damages, including damages for loss of profits, goodwill, use, or data or other losses, **even if we have been advised of the possibility of such damages.** our aggregate liability under these terms will not exceed the greater of the amount you paid for the service that gave rise to the claim during the 12 months before the liability arose or one hundred dollars (\$100). the limitations in this section apply only to the maximum extent permitted by applicable law.

(continua...)

## RISCOS : RESPONSABILIDADE



(...)

- **"Indemnity:** If you are a business or organization, to the extent permitted by law, **you will indemnify and hold harmless** us, our affiliates, and our personnel, from and against any costs, losses, liabilities, and expenses (including attorneys' fees) from third party claims arising out of or relating to your use of the Services and Content or any violation of these Terms.

Ainda que o exemplo apresentado seja da OpenAI e seja relativo a soluções de GenAI, um caso particular de Deep Learning, este risco é transversal e real.

<https://openai.com/policies/terms-of-use>

## RISCOS : ENVIESAMENTOS &amp; PRECONCEITOS



Não sendo um risco particular de soluções de Deep Learning, é um risco claramente potenciado pelo nível de complexidade.

A **clara dependência** da qualidade, veracidade, representatividade, etc. **dos dados** torna as soluções de **Deep Learning** muitos suscetíveis de gerar **outputs enviesados** ou que **replicam preconceitos** automaticamente.

É necessário, após desenvolvimento destes modelos, **testa-los com respeito a um conjunto de medidas éticas**.

Iremos falar desse tema no capítulo final deste curso.



## RISCOS : FRAUDE &amp; CYBERCRIME



Quando mais complexa é a nossa realidade, mas difícil é de garantir que não há falhas de segurança.

Por um lado temos Deep Learning a serem usadas para combater a Fraude, **por outro lado são usadas para identificar falhas nos sistemas** e explora-las.

Infelizmente, a existência de melhores soluções, não irá diminuir a incidência de fraude e cybercrime, pois é usada “dos 2 lados”.

Têm-se verificado situações de uso deste tipo de modelos em:

- Roubo de identidade
- Exploração de vulnerabilidade de sistemas
- Fake news

## RISCOS : ABUSO DE PODER

EDIT.

Tipicamente as ferramentas que temos ao nosso dispor **não têm uma característica ética per si**, não são “boas” nem “más”.

O que determina se a ferramenta trás, ou não valor, é o **uso que lhe é dada**, e quanto maior o poder da ferramenta, maior o impacto que poderá ter, positivo ou negativo.

As soluções baseadas em **Deep Learning**, ao terem uma elevada capacidade de:

- Interpretar de padrões
- Explicar fenómenos
- Prever futuros eventos
- Gerar conteúdos
- ...



33

## RISCOS : ABUSO DE PODER

EDIT.

...tem **tendência para criar um desequilíbrio** entre quem usa as ferramentas e quem é alvo da aplicação das mesmas.

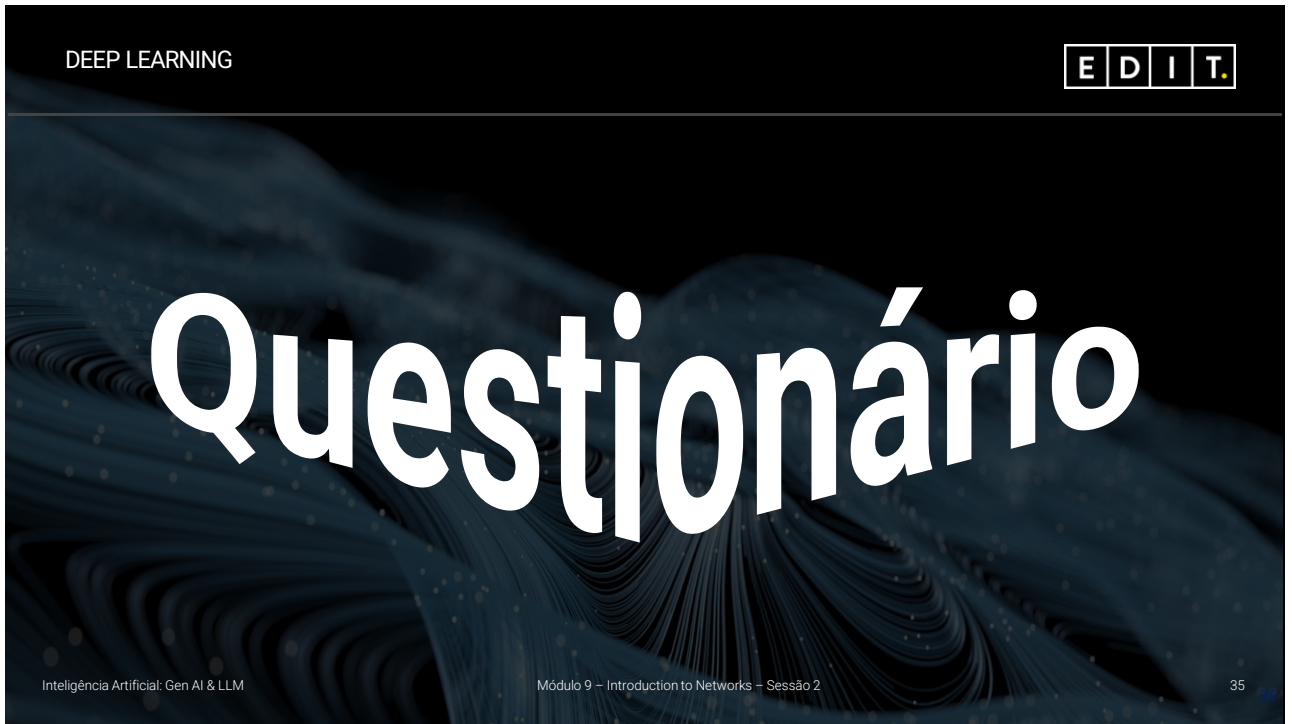
Um exemplo disso é o uso destas soluções em **propaganda política** ou marketing.

Ainda que tenhamos acesso a informação privilegiada, ainda que possamos beneficiar do seu uso, é CRUCIAL compreender em que cenários é ético a utilizar.

**Os fins não justificam os meios.** O poder que estas ferramentas nos atribuem, tem de ser equiparado à **nossa responsabilidade** para as usar.



34



DEEP LEARNING

EDIT.

# Questionário

Inteligência Artificial: Gen AI & LLM

Módulo 9 – Introduction to Networks – Sessão 2

35